

تمرین شماره ۲:

۱. تمرینات عملی

هدف از این تمرین آشنایی با روش‌های کلاسیک تعبیه‌سازی (Embedding) واژه‌ها و متون و به‌کارگیری آن‌ها در مسائل طبقه‌بندی متن با استفاده از الگوریتم‌های یادگیری ماشین (نظیر رگرسیون لجستیک، SVM یا k-NN) است. در این تمرین دو مسئله طبقه‌بندی مستقل را پیاده‌سازی خواهید کرد.

پیش‌نیازها: کتابخانه‌های `numpy`, `scikit-learn`, `gensim`, `nlTK`.

۱-۱. طبقه‌بندی احساسات (Sentiment Analysis) با مدل تعبیه آموزش داده‌شده روی داده آموزشی

در این بخش شما یک مدل تعبیه واژگان (`word2vec`) را تنها بر روی بخش آموزش از یک مجموعه داده کوچک نقد فیلم آموزش می‌دهید و سپس با میانگین‌گیری بردارهای واژه‌های هر نقد، از آن برای طبقه‌بندی دودویی نقدهای مثبت، منفی استفاده می‌کنید.

مجموعه داده: (IMDb polarity dataset (Pang & Lee)، شامل ۲۰۰۰ نقد فیلم (۱۰۰۰ مثبت و ۱۰۰۰ منفی). این داده از طریق `nlTK.corpus.movie_reviews` در دسترس است.

مراحل خط لوله (Pipeline):

۱. بارگذاری و توکن‌سازی ساده. تبدیل به حروف کوچک و جداسازی بر اساس فاصله.

۲. تقسیم داده به ۸۰٪ آموزش و ۲۰٪ آزمون با رعایت توازن کلاس‌ها (به رویکرد Stratify Splitting توجه شود^۱). همین‌طور مجموعه داده‌های آموزش و آزمون را ذخیره کنید و سپس در طبقه‌بندی از همین مجموعه داده‌ها استفاده کنید.

۳. آموزش مدل **Word2Vec** (با ابعاد ۱۰۰، `window=۵`، `min_count=۲`)

۴. برای هر سند (آموزش و آزمون)، میانگین بردارهای واژه‌های موجود محاسبه شود؛ واژه‌هایی که در واژگان مدل نیستند نادیده گرفته شوند و در صورت نبود هیچ واژه شناخته شده، بردار صفر در نظر گرفته شود. (به نظر شما چرا در اینجا از میانگین بردارها استفاده می‌کنیم؟)

۱. توزیع داده‌های آزمایش باید تا حد امکان با توزیع داده‌های آموزش مطابقت داشته باشد، داده‌ها باید به گونه‌ای تقسیم شوند که اگر داده‌های آموزش شامل ۸۰٪ برچسب‌های ۱ و ۲۰٪ برچسب‌های ۰ باشند، داده‌های آزمایش نیز شامل برچسب‌هایی با نسبت‌های مشابه باشند.

۵. طبقه‌بندی با رگرسیون لجستیک (LogisticRegression) و نیز k-NN (KNeighborsClassifier) بر اساس معیار cosine روی بردارهای نرمال‌شده. (از روش L_2 استفاده کنید)

۶. گزارش صحت (Accuracy) و ماتریس درهم‌ریختگی (Confusion Matrix)

پرسش‌های تحلیلی:

الف) تأثیر پارامتر vector_size (۵۰، ۱۰۰، ۲۰۰) بر دقت نهایی را بررسی کنید. (vector_size، به طور پیش‌فرض در کتابخانه Genism موجود است)

ب) به نظر شما چرا نباید مدل تعبیه را روی کل داده آموزش داد؟

ج) کدام طبقه‌بند (رگرسیون لجستیک یا k-NN) عملکرد بهتری دارد و چرا؟

۱-۲. طبقه‌بندی چند کلاس مقالات خبری با مدل تعبیه از پیش آموزش‌دیده (Pre-trained):

در این بخش شما از بردارهای مدل تعبیه از پیش آموزش‌دیده GloVe برای بازنمایی اسناد استفاده می‌کنید و یک مسئله ۵ کلاس (موضوع خبر) را حل می‌کنید.

مجموعه داده BBC News dataset، شامل ۲۲۲۵ مقاله خبری در ۵ طبقه:

[Tech, Sport, Politics, Entertainment, Business] است.

مجموعه داده را از شناسه مقابل: <http://mlg.ucd.ie/files/datasets/bbc-fulltext.zip> دانلود کرده و از حالت فشرده خارج کنید.

بردارهای از پیش آموزش‌دیده GloVe ۱۰۰ بعدی را (اسم فایل: glove.6B.100d.txt) از آدرس مقابل دانلود کرده (<https://nlp.stanford.edu/data/glove.6B.zip>) و با استفاده از کد مقابل، آن را آماده استفاده کنید:

```
from gensim.scripts.glove2word2vec import glove2word2vec
from gensim.models import KeyedVectors

# Step 1: Convert GloVe format to Word2Vec format
glove2word2vec("glove.6B.100d.txt", "glove.6B.100d.word2vec.txt")

# Step 2: Load with Gensim
model = KeyedVectors.load_word2vec_format("glove.6B.100d.word2vec.txt",
binary=False)
```

مراحل خط لوله:

۱. خواندن مقالات از پوشه‌های هر کلاس و توکن‌سازی مشابه قبل.
 ۲. تقسیم داده به ۸۰٪ آموزش و ۲۰٪ آزمون (با حفظ نسبت کلاس‌ها در دو بخش، همانند سؤال قبل).
 ۳. بارگذاری بردارهای مدل GloVe.
 ۴. برای هر سند، میانگین بردارهای GloVe کلمات موجود محاسبه شود (واژه‌های خارج از واژگان GloVe نادیده گرفته شوند).
 ۵. طبقه‌بندی با رگرسیون لجستیک (با استفاده از `multi_class='ovr'`) و یک الگوریتم طبقه‌بند دیگر (مانند SVM، درخت تصمیم، XGboost و غیره) به دلخواه خودتان.
 ۶. گزارش دقت و ماتریس درهم‌ریختگی به ازای هر کلاس.
- پرسش‌های تحلیلی:

- الف) چه درصدی از واژه‌های مجموعه BBC در واژگان GloVe پوشش داده می‌شوند؟ (درصد واژه‌های خارج از واژگان (Out of Vocabulary) را در صورت وجود بیان کنید).
- ب) به صورت دلخواه خود، این واژه‌ها را برای GloVe افزایش دهید و نتیجه طبقه‌بند را گزارش دهید. **(اختیاری)**
- ج) بر اساس ماتریس درهم‌ریختگی، کدام جفت کلاس‌ها بیشتر با یکدیگر اشتباه گرفته می‌شوند؟
- د) اگر به جای GloVe با ابعاد ۱۰۰ از GloVe با ابعاد ۵۰ استفاده کنید، آیا دقت تغییر می‌کند؟ (این نسخه از GloVe نیز همان ر لینک بالا در دسترس است. اجرا بگیرید و نتیجه را تحلیل کنید)
- ه) دو الگوریتم طبقه‌بندی را از حیث نتایج با یکدیگر مقایسه کنید. به نظر شما کدام یک عملکرد بهتری دارد و چرا؟
- و) مقایسه‌ای مفهومی بین رویکرد آموزش مدل تعبیه از ابتدا و استفاده از مدل تعبیه از پیش آموزش‌دیده ارائه دهید (مقایسه بین قسمت ۱-۱ و ۱-۲). در چه شرایطی هر یک ترجیح داده می‌شود؟
- تذکر مهم: در هر دو بخش، رعایت تفکیک داده آموزش و آزمون پیش از هرگونه پردازش الزامی است.