

بخش اول، پرسش‌های مفهومی:

سؤال ۱. گذار از بازگشت (Recurrent) به خود توجهی (Self-Attention)

در سالیان اخیر، معماری‌های جدید در حوزه پردازش زبان از مدل‌های دنباله‌ای بازگشتی^۱ به معماری‌های مبتنی بر توجه^۲ و در نهایت ترنسفورمرها تکامل یافته‌اند. محدودیت‌های نمایش‌های بازگشتی را که منجر به معرفی سازوکار توجه شدند توضیح دهید. سپس تشریح کنید که خود توجهی چگونه جریان اطلاعات، مدل‌سازی وابستگی‌ها^۳، موازی‌سازی محاسبات و مقیاس‌پذیری را دگرگون می‌کند. در ادامه، مزایا و معایب رویکردهای بازگشتی و مبتنی بر خود توجهی را از منظر سوگیری القایی^۴، بهره‌وری داده و مقیاس‌پذیری مدل تحلیل کرده و توضیح دهید چرا ترنسفورمرها به معماری غالب در مدل‌های زبانی بزرگ تبدیل شده‌اند.

سؤال ۲. مقایسه BiLSTM+Attention و مدل‌های زبانی مبتنی بر ترنسفورمر

یک مدل BiLSTM مجهز به مکانیزم توجه و یک مدل زبانی بزرگ مبتنی بر ترنسفورمر از نوع خود همبسته^۵ هر دو نمایش‌های محیط آگاه^۶ تولید می‌کنند. این دو رویکرد را با یکدیگر مقایسه کنید. سپس، دو کاربرد را معرفی کنید که در آن‌ها BiLSTM+Attention همچنان انتخابی منطقی است و دو کاربرد را بیان کنید که در آن‌ها استفاده از یک مدل زبانی بزرگ مبتنی بر ترنسفورمر به وضوح ترجیح داده می‌شود.

سؤال ۳. روش‌های تنظیم دقیق^۷ کم پارامتر به عنوان یک فضای طراحی

روش‌های Parameter-Efficient Fine-Tuning (PEFT)^۸ عمدتاً در محل و نحوه تزریق اطلاعات وظیفه‌محور به مدل از پیش آموزش دیده با یکدیگر تفاوت دارند. با این دیدگاه، روش‌های زیر را مقایسه کنید:

- **Hard Prompt Tuning**
- **Soft Prompt Tuning**
- **Prefix Tuning**
- **Adapter Tuning**
- **LoRA**

۱. Recurrent Sequence Models

۲. Attention Mechanism

۳. Dependency Modeling

۴. Inductive Bias

۵. Autoregressive

۶. Context-Aware

۷. Fine Tune

۸. تنظیم دقیق پارامتر کارا

- QLoRA

برای هر روش موارد زیر را توضیح دهید:

۱. کدام بخش از مدل یا فرایند محاسباتی مدل تغییر می‌کند؟
۲. مبادله میان ظرفیت سازگاری^۱ و بهره‌وری پارامتری^۲.
۳. یک سناریو که در آن روش موردنظر انتخابی مناسب است.
۴. یک سناریو که در آن انتخاب مناسبی نیست.

(پاسخ خود را بر اساس روش‌ها سازمان‌دهی کنید، نه بر اساس سناریوها.)

سؤال ۴. سازگارسازی مدل تحت محدودیت منابع

فرض کنید یک مدل زبانی از پیش آموزش دیده با ۷ میلیارد پارامتر و یک مجموعه داده تخصصی^۳ شامل ۵۰ هزار نمونه برچسب خورده در اختیار دارید. هدف، سازگارسازی مدل با این حوزه تخصصی از طریق تنظیم دقیق و سپس استقرار مدل حاصل برای استفاده در کاربردهای عملی است. همچنین تنها به یک GPU با ۱۶ گیگابایت حافظه دسترسی دارید و مدل نهایی باید روی سخت‌افزارهای متداول قابل اجرا باشد.

یک راهبرد مناسب برای فرایند تنظیم دقیق ارائه دهید که شامل انتخاب یک روش PEFT و یک طرح کوانتیزه‌سازی برای استقرار مدل نهایی باشد. انتخاب‌های خود را از نظر بهره‌وری حافظه، ظرفیت سازگاری با داده‌های تخصصی، عملکرد موردانتظار مدل و محدودیت‌های استقرار توجیه کنید. همچنین توضیح دهید مدل سازگارسازی شده چگونه ذخیره، بارگذاری و در محیط عملیاتی مورد استفاده قرار خواهد گرفت؟

۱. Adaptation Capacity

۲. Parameter Efficiency

۳. Domain Specific

بخش دوم، پرسش‌های عملی و پیاده‌سازی:

موارد تحویلی شامل سه Notebook اجرا شده در Kaggle یا Colab (برای هر زیر تمرین یک Notebook)، یک گزارش PDF شامل تحلیل نتایج، و فایل Adapter ذخیره شده برای تمرین‌های ۲-۲ و ۲-۳ است.

توجه مهم: در همه موارد فقط از مدل Qwen۲,۵-۳B-Instruct استفاده کنید.

۲-۱. استنتاج LLM کوانتیزه شده روی Prompt های فارسی

مدل Qwen/Qwen۲,۵-۳B-Instruct را در سه حالت زیر بارگذاری کنید:

برای هر نسخه کوانتیزه شده ($FP^{۱۶}$ ، $INT^۸$ و $INT^۴/NF^۴$)، سه وظیفه زیر را اجرا کنید و نتایج را ثبت کنید.

برای هر وظیفه، موارد زیر را گزارش کنید:

۱. مصرف حافظه (GPU (Peak VRAM):

مقدار بیشینه حافظه GPU که مدل هنگام اجرا استفاده می‌کند را اندازه‌گیری کنید. این معیار نشان می‌دهد هر روش کوانتیزه‌سازی چه مقدار حافظه نیاز دارد.

۲. زمان استنتاج (Latency):

زمان لازم برای تولید پاسخ مدل از لحظه ارسال ورودی تا دریافت خروجی را اندازه‌گیری کنید. برای دقت بیشتر، چند بار اجرا کرده و میانگین زمان را گزارش کنید.

برای این مورد، فقط از کانفیگ مقابل استفاده کنید:

temperature=0

do_sample=False

max_new_tokens=128

۳. سرعت تولید متن (Tokens/sec):

تعداد توکن‌هایی که مدل در هر ثانیه تولید می‌کند را محاسبه کنید. مقدار بیشتر نشان‌دهنده تولید سریع‌تر متن است.

۴. کیفیت خروجی مدل:

خروجی تولیدشده برای سه وظیفه زیر را ذخیره و مقایسه کنید:

ترجمه فارسی به انگلیسی

خلاصه سازی متن فارسی

طبقه بندی احساسات فارسی (مثبت، منفی، خنثی)

نتایج را در جدولی همانند زیر گزارش کنید:

Precision	VRAM (GB)	Latency (sec)	Tokens/sec	Translation Output	Summarization Output	Sentiment Output
FP۱۶						
INT۸						
NF۴- INT۴						

سپس پاسخ دهید:

۱. کدام وظیفه بیشترین افت کیفیت را تحت کوانتیزه سازی نشان می دهد؟

۲. کدام وظیفه در مقابل کوانتیزه سازی، مقاوم تر است؟

۳. به طور خلاصه درباره نتایج جدول و سؤالات بالا، نظر خود را در باره کوانتیزه سازی این مدل بیان کنید.

تحویل: Notebook اجراشده، جدول مقایسه و یک تحلیل کوتاه حدود ۲۰۰ تا ۳۰۰ کلمه ای.

۲-۲. تنظیم دقیق QLoRA برای تحلیل احساسات فارسی

از مجموعه داده زیر استفاده کنید:

hezarai/sentiment-dksf (<https://huggingface.co/datasets/hezarai/sentiment-dksf>)

این مجموعه داده شامل حدود ۲۸ هزار نمونه آموزش و ۲۳۰۰ نمونه آزمون با سه کلاس زیر است:

مثبت، منفی، خنثی

الزامات پیاده‌سازی:

۱. مدل پایه را با کوانتیزه‌سازی NF^۴ چهار بیتی بارگذاری کنید.

۲. از QLoRA و PEFT استفاده کنید.

۳. داده‌ها را به قالب Instruction Tuning یا Chat Format تبدیل کنید. (ارزیابی باید با تولید برچسب‌های کلاس در قالبی محدود انجام شود).

مثال:

ورودی:

متن: ...

احساس:

خروجی:

مثبت

۴. مدل را به مدت یک Epoch آموزش دهید.

برای جلوگیری از خطاهای حافظه، می‌توانید از موارد زیر استفاده کنید:

حداکثر طول ورودی: ۵۱۲ توکن

Batch Size کوچک (۱ یا ۲) همراه با Gradient Accumulation

اگر به هر دلیل مشکل سخت‌افزار داشتید و یا در صورت مشکل حافظه یا زمان، می‌توانید از یک زیرمجموعه Stratified حدود ۸۰۰۰ نمونه‌ای استفاده کنید. (نمونه‌گیری Stratified روشی است که در آن داده‌ها ابتدا به چند گروه (مثلاً بر اساس کلاس‌ها) تقسیم می‌شوند و سپس از هر گروه به نسبت اندازه آن نمونه انتخاب می‌شود. هدف این است که توزیع کلاس‌ها در نمونه کوچک‌شده شبیه Dataset اصلی باقی بماند. برای مثال، اگر داده شامل ۵۰٪ مثبت، ۳۰٪ منفی و ۲۰٪ خنثی باشد، نمونه جدید نیز تقریباً همین نسبت را حفظ می‌کند) توجه: توصیه می‌شود که تا جای

ممکن از این روش استفاده نکنید. زیرا تمرین در حالتی طراحی شده که بتوانید بر روی GPU ذکر شده موارد را انجام دهید. استفاده از این روش ممکن است باعث کسر نمره شود.

در این حالت موارد زیر را گزارش کنید:

الف) مقدار Seed تصادفی

ب) روش نمونه‌گیری

ج) تعداد نهایی نمونه‌های آموزش

مدل را روی Test Set ارزیابی کنید و موارد زیر را گزارش دهید:

الف) Accuracy

ب) F1-Macro

نتایج را برای دو حالت زیر مقایسه کنید (با پرامپت یکسان):

۱. قبل از تنظیم دقیق

۲. بعد از تنظیم دقیق

همچنین تعداد پارامترهای قابل آموزش (Trainable Parameters) را گزارش کنید.

مرحله تحلیل خطا:

حداقل پنج نمونه اشتباه طبقه‌بندی شده پس از تنظیم دقیق را بررسی کنید و توضیح دهید خطاها بیشتر ناشی از کدام عوامل هستند؟

۱. ابهام معنایی ۲. واژگان خاص دامنه ۳. احساس ضمنی یا کنایه ۴. محدودیت مدل ۵. محدودیت داده

تحویل: Notebook اجرا شده، فایل‌های Adapter شامل adapter_config.json و adapter_model.safetensors، نتایج و یک تحلیل کوتاه.

۲-۳. مقایسه عملی دو روش PEFT برای سازگارسازی یک مدل زبانی کوانتایز شده

تمرین ۲-۲ را با استفاده از یک روش دیگر تنظیم دقیق کم پارامتر (PEFT) تکرار کنید. در این مقایسه، برای اطمینان از عادلانه بودن آزمایش، موارد زیر باید در هر دو روش ثابت باقی بمانند:

۱. مدل پایه کوانتایز شده ۲. مجموعه داده ۳. روش پیش پردازش داده ها ۴. تقسیم بندی Train/Test ۵. قالب Prompt یا Chat Template ۶. تعداد Epoch های آموزش ۷. معیارهای ارزیابی

از آنجاکه روش های مختلف PEFT ظرفیت سازگاری متفاوتی دارند، تعداد پارامترهای قابل آموزش باید در دو روش تقریباً مشابه باشد؛ بنابراین، روش انتخابی را طوری تنظیم کنید که بودجه پارامترهای قابل آموزش (Trainable Parameter Budget) نزدیک به روش پایه باشد. هدف این است که تفاوت عملکرد ناشی از تفاوت روش PEFT باشد، نه صرفاً تفاوت تعداد پارامترهای آموزش داده شده.

تنظیمات پیشنهادی:

روش اول، LoRA

LoRA Configuration:

`r = 16`

`lora_alpha = 32`

`target_modules = "all-linear"`

در صورت نیاز، مقدار r را تغییر دهید تا تعداد پارامترهای قابل آموزش با روش دوم قابل مقایسه شود. در LoRA، مقدار r یکی از عوامل اصلی تعیین کننده تعداد پارامترهای قابل آموزش است. همچنین استفاده از `"target_modules="all-linear"` مطابق رویکرد QLoRA باعث اعمال Adapter روی تمام لایه های خطی مدل می شود.

روش دوم، Prefix Tuning :

Prefix Tuning Configuration:

`num_virtual_tokens = 20`

در صورت نیاز، تعداد توکن‌های مجازی را تغییر دهید تا تعداد پارامترهای قابل آموزش تقریباً با روش LoRA برابر شود. در Prefix Tuning، به جای تغییر وزن‌های مدل، بردارهای قابل آموزش به عنوان Prefix به لایه‌های Transformer اضافه می‌شوند.

موارد گزارش:

برای هر دو روش، موارد زیر را گزارش کنید:

PEFT	روش	پارامترهای قابل آموزش	Peak VRAM	زمان آموزش	Accuracy	F1-Macro
------	-----	-----------------------	-----------	------------	----------	----------

سپس تحلیل کنید:

کدام روش با تعداد پارامتر مشابه، عملکرد بهتری ارائه می‌دهد؟

کدام روش حافظه کمتری مصرف می‌کند؟

کدام روش زمان آموزش کوتاه‌تری دارد؟

در پایان، یک روش را برای این مسئله تحت محدودیت منابع پیشنهاد دهید و انتخاب خود را توجیه کنید.

قوانین تحویل:

۱. سه Notebook اجرا شده و یک گزارش PDF تحویل دهید.

۲. فقط فایل Adapter ارسال شود و وزن‌های مدل پایه ارسال نشوند.

۳. جداسازی Train/Test باید قبل از هرگونه Preprocessing رعایت شود.

۴. هرگونه Data Leakage موجب دریافت نمره صفر برای آن بخش خواهد شد.

۵. در صورت استفاده از زیر نمونه‌گیری، Seed، روش Stratification و تعداد نهایی داده‌ها گزارش شود.