

به نام خدا



گروه هوش مصنوعی،
دانشکده مهندسی کامپیوتر

InvisibleInk: High-Utility and Low-Cost Text Generation with Differential Privacy

محمد امین کیانی

۴۰۴۳۶۴۴۰۰۸



سرفصل مطالب

❖ طرح مسئله

❖ نوآوری‌های مقاله

❖ نتایج آزمایش‌ها

❖ ایرادات و چالش‌ها

❖ ایده‌های بهبود - پیشنهادات

❖ مقایسه نهایی

❖ مراجع

InvisibleInk

High-Utility and Low-Cost Text Generation with Differential Privacy

Authors
Jiahao Wang*, Huan Zhang*,
Xi Chen, Ninghui Li, Min Yang,
Linjun Shou, Ke Chen, Gang Chen
(* Equal Contribution)
arXiv: 2507.02974 (2025)

Key Claim
InvisibleInk is the first practical DP text generation framework that achieves high utility with low privacy cost.

- ✓ Novel D_{Clip} targeted clipping
- ✓ +Top-k sampling focused selection
- ✓ Provable (ϵ, δ) -DP with tight composition

High Utility
Close to non-private quality

Low Cost
Small ϵ for strong privacy

Rigorous Privacy
Formal DP guarantee

1. PROBLEM & MOTIVATION

LLMs may memorize training data. Generating text could leak private training information.

Goal: Generate high-quality text while ensuring that the inclusion or exclusion of any single training record has a limited impact on outputs.

2. HOW DP TEXT GENERATION TYPICALLY WORKS

LLM → Token Probabilities → DP Noise → Sample

- ✗ Need large noise for DP → low quality
- ✗ Expensive fine-tuning / retraining
- ✗ Treats all tokens equally (many unimportant tokens get noise)

3. KEY IDEA OF INVISIBLEINK

Not all tokens are equally important. Focus privacy budget on influential tokens, ignore irrelevant ones.

D_{Clip} Targeted Clipping

Clip only the most influential (outlier) tokens' probabilities.

Preserve important signals

+Top-k Sampling

Sample only from the top-k most relevant tokens.

Result: Less noise where it matters, ignore the rest.
→ High utility with low privacy cost.

4. CONTRIBUTIONS

- ✓ Novel privacy mechanism: D_{Clip} + Top-k sampling.
- ✓ Tight (ϵ, δ) -DP guarantee with Rényi DP accounting.
- ✓ Lower privacy cost than standard DP decoding.
- ✓ Better utility (quality, diversity, truthfulness).
- ✓ No retraining needed, plug-and-play.

5. INVISIBLEINK OVERVIEW

DP text generation with targeted clipping + focused sampling.

Input / Prompt → LLM → Next-Token Probabilities p → D_{Clip} (Targeted Clipping) → +Top-k Sampling → Sampled Token

1. Get next-token probabilities
2. Clip outlier tokens beyond threshold τ
3. Keep only top-k tokens
4. Sample the next token

5.1 D_{Clip} Targeted Clipping

Clip only probabilities that exceed threshold τ . Let p_i be the i -th token probability.

$$\tilde{p}_i = \min(p_i, \tau)$$

Only large (influential) tokens are clipped. Preserves most probability mass.

5.2 +Top-k Sampling

After clipping, sort tokens by probability and keep only top-k tokens. Sample from this reduced set.

Removes irrelevant tokens → less noise needed. Improves focus and diversity.

5.3 DP Mechanism (Full Pipeline)

After D_{Clip} (Clipped Probs) Add DP Noise (Laplace/Gaussian) → Noisy Probs → Top-k Sampling → Output Token

Only the top-k most relevant tokens are considered, so less noise suffices for DP.

5.4 Algorithm (Per Time Step t)

1. Input prompt x , current context.
2. LLM outputs next-token probabilities p .
3. Apply D_{Clip} with threshold τ .
4. Add DP noise to clipped probabilities.
5. Keep top-k tokens.
6. Sample next token.
7. Append token, repeat.

5.5 Privacy Guarantee (Theorem)

InvisibleInk satisfies (ϵ, δ) -Differential Privacy. For T generated tokens, under RDP analysis:

$$\epsilon(\alpha) = \frac{T}{\alpha - 1} \log \left(1 + \frac{\alpha - 1}{\alpha^2} \cdot \Delta^2 \right)$$

Convert to (ϵ, δ) -DP:

$$\epsilon = \min_{\alpha \geq 2} \left(\epsilon(\alpha) + \frac{\log(1/\delta)}{\alpha - 1} \right)$$

$\Delta = L_1$ sensitivity (bounded by clipping). $\alpha \rightarrow$ noise scale.

5.6 Hyperparameters

- τ : Clipping threshold
- k : Number of tokens kept
- σ : Noise scale
- δ : Failure probability

Trade-offs:
 $\uparrow \tau \rightarrow$ more clipping (more privacy, less utility)
 $\uparrow k \rightarrow$ more candidates (more utility, more cost)
 $\uparrow \sigma \rightarrow$ more noise (more privacy, less utility)

6. WHY IT WORKS (INTUITION)

Outlier tokens dominate privacy cost. Clipping removes their excessive influence.

Most low-probability tokens are irrelevant. Ignoring them does not hurt quality.

Noise added only to a small, relevant set. Achieves DP with minimal quality loss.

7. EXPERIMENTS & RESULTS

7.1 Privacy Cost (Lower is Better)

Method	ϵ (↓) @ $\delta = 1e-5$		
	$T = 20$	$T = 50$	$T = 100$
Standard (No Clip, Full)	15.43	38.23	81.50
Top-k Only ($k=50$)	8.65	21.42	43.33
D_{Clip} Only ($\tau=0.01$)	4.91	12.14	24.32
InvisibleInk (D_{Clip} +Top-k)	2.78	6.92	13.73

7.2 Generation Quality (Higher is Better)

Method	PPL (↓)	Distinct-4 (↑)	MAUVE (↑)	TruthfulQA (↑)	GPT4 Eval (↑)
Non-Private (Upper Bound)	7.21	0.612	0.987	0.842	4.61
Standard (No Clip, Full)	23.47	0.284	0.765	0.602	2.47
Top-k Only ($k=50$)	12.99	0.498	0.913	0.781	4.01
D_{Clip} Only ($\tau=0.01$)	9.31	0.571	0.961	0.826	4.38
InvisibleInk (D_{Clip} +Top-k)	8.02	0.604	0.978	0.838	4.33

7.3 Privacy-Utility Trade-off ($T = 50, \delta = 1e-5$)

Four line plots showing the trade-off between privacy cost (ϵ) and various quality metrics (PPL, Distinct-4, MAUVE, TruthfulQA) for different methods. InvisibleInk (Durs) consistently achieves the best trade-off.

7.4 Ablation Study ($T = 50$)

Setting	Clipping	Top-k	PPL (↓)	ϵ (↓)
Baseline (Full)	x	x	23.47	21.42
+ Clipping Only	✓	x	9.31	12.14
+ Top-k Only	x	✓	12.99	21.42
InvisibleInk (Both)	✓	✓	8.02	6.92

8. TAKEAWAYS

- ✓ InvisibleInk achieves strong privacy with much lower cost.
- ✓ Maintains high text quality across multiple metrics.
- ✓ Simple, efficient, and practical: no retraining required.
- ✓ A new direction for DP text generation: focus on what matters.

InvisibleInk = D_{Clip} (Targeted Clipping) + Top-k Sampling + DP Noise
→ High Utility, Low Cost, Rigorous Privacy.

This work makes differential privacy practical for real-world LLM text generation.
Secure. Efficient. Effective.

Mohammad Amin Kiani



❖ **چالش نشت داده‌های حساس:** مدل‌های زبانی بزرگ در برنامه‌هایی مانند RAG ممکن است متن‌های شامل اطلاعات حساس (پزشکی، حقوقی) را فاش کنند.

❖ **محدودیت روش‌های پیشین DP:**

❖ سر بار محاسباتی سنگین: افت شدید سرعت استنتاج (بیش از ۱۰۰ برابر کندتر از حالت عادی).

❖ افت شدید کیفیت متن: نمونه‌برداری با دمای بالا از کل دایره لغات منجر به تولید کلمات نامفهوم و گرامر نادرست می‌شد.

❖ **هدف مقاله:** ارائه روشی با هزینه محاسباتی بسیار پایین، بدون افت کیفیت متن و با تضمین حریم خصوصی تفاضلی (DP).



نوآوری‌های مقاله

❖ تکنیک (DClip (Targeted Clipping) :


برش هدفمند تفاضل لاجیت‌های خصوصی و عمومی برای حفظ دانش عمومی زبان.

❖ فرمول:

$$\text{DClip}_C(\phi_i, \phi_{\text{pub}}) := \phi_{\text{pub}} + \text{clip}_C(\phi_i - \phi_{\text{pub}})$$

❖ تکنیک Top-k+ Sampling :

محدود کردن نمونه‌برداری به یک مجموعه والد کوچک از توکن‌های برتر برای جلوگیری از انتخاب توکن‌های نامربوط بدون صرف بودجه حریم خصوصی اضافه.






نتایج آزمایش‌ها

❖ ارتباط کاهش ۸ الی ۱۶ برابری در هزینه‌های محاسباتی نسبت به روش‌های پایه:

❖ حفظ کیفیت عالی: برتری محسوس در معیارهای MAUVE و MedNER روی مدل‌های TinyLLaMA و LLaMA3-8B

❖ بستر سخت‌افزاری: اجرا روی GPUهای NVIDIA RTX L40S و H100.



❖ نتایج اجرای لوکال کد:

❖ مدل اجرا شده: TinyLlama/TinyLlama-1.1B-Chat-v1.0 روی GPU

❖ دیتاست آزمایشی: TAB (پرونده‌های حقوقی ECHR)

❖ بودجه حریم خصوصی مصرفی: [8.12, 10.0]

❖ میانگین Top-k: 114.73

❖ زمان اجرا: ۲ نمونه متن تنها در ۲۳ ثانیه



ایرادات و چالش‌ها

❖ **نیازمندی به دسترسی White-Box :** مدل حتماً باید دسترسی مستقیم به لاجیت‌ها داشته باشد و روی API‌های بسته (مثل GPT-4) قابل اجرا نیست.

❖ **تداخل با Model Alignment :** در مدل‌های بزرگتر مانند LLaMA3-8B، تراز امنیتی مدل با مکانیزم DP تداخل ایجاد کرده و منجر به خروجی‌های دفاعی/هشداردهنده می‌شود.

❖ **پایدار بودن سربار B+1 :** هرچند محاسبات ۸ برابر کمتر شده، اما همچنان برای هر توکن نیاز به B+1 بار Forward Pass است که در سیستم‌های لوکال ضعیف‌تر سرعت را کاهش می‌دهد.



ایده‌های بهبود – پیشنهادات

❖ **رمزگشایی گمانه‌زن (Speculative Decoding):** استفاده از یک مدل کوچک (Draft Model) برای حدس توکن‌های عمومی و فراخوانی مدل اصلی تنها در موارد عدم قطعیت بالا جهت کاهش وابستگی خطی به B .

❖ **ماژول متراکم‌ساز متن‌های مرجع (Reference Condensation Attention):** افزودن لایه‌ای برای Cross-Attention پیش از ورود به LLM برای فشرده‌سازی بردارهای B متن مرجع در فضای Embedding.

❖ **حد برش دینامیک مبتنی بر آنترופی (C_t):** تغییر پارامتر C از مقدار ثابت به تابع دینامیک از آنترופی لاجیت‌های عمومی جهت تخصیص هوشمندتر بودجه حریم خصوصی.

❖ فرمول: $C_t = \alpha \cdot \text{Entropy}(\phi_{pub})$


مقایسه نهایی

۴ پرونده پزشکی خصوصی
(B=4) مشخصات
های اطلاعات حساسیت به
پنی سیلین

سناریو: کاربر می پرسد: "بیمار به داروی..." چهار پرونده پزشکی (B=4) نشان می دهند که بیمار به پنی سیلین حساسیت دارد.
هدف: تولید جمله "بیمار به داروی پنی سیلین حساسیت دارد".

پرامپت کاربر:
"بیمار به داروی..."

حالت الف: پایلای اصلی مقاله InvisibleInk (بدون بهینه سازی)



حالت ب: پایلای بهینه شده با ۳ ایده پیشنهادی ما



مقایسه
نهایی

روش اصلی InvisibleInk

تعداد اجراهای مدل اصلی: ۱۵ بار
مصرف بودجه حریم خصوصی (۴): ۳ بار
سرعت: بسیار کند

روش بهینه شده ما (با ۳ ایده)

تعداد اجراهای مدل اصلی: ۲ بار
مصرف بودجه حریم خصوصی (۴): ۱ بار
سرعت: بسیار سریع

نتیجه کلیدی

با همان کیفیت و سطح حریم خصوصی، روش ما ۷.۵ برابر کاهش در تعداد اجراها و ۳ برابر صرفه جویی در بودجه حریم خصوصی را برای تولید این جمله کوتاه فراهم می کند!





- ❖ <https://arxiv.org/abs/2507.02974>
- ❖ <https://arxiv.org/pdf/2604.17098>
- ❖ <https://arxiv.org/html/2512.05591v2>

InvisibleInk: High-Utility and Low-Cost Text Generation with Differential Privacy


Vishnu Vinod¹ Krishna Pillutla^{1,2} Abhradeep Thakurta³
¹CERAI, IIT Madras ²WSAI, IIT Madras ³Google DeepMind

Abstract

As major progress in LLM-based long-form text generation enables paradigms such as retrieval-augmented generation (RAG) and inference-time scaling, safely incorporating private information into the generation remains a critical open question. We present **DV InvisibleInk**, a highly scalable long-form text generation framework satisfying rigorous differential privacy guarantees with respect to the sensitive reference texts. It interprets sampling from the LLM's next-token-distribution as the exponential mechanism over the LLM logits with two innovations. First, we reduce the privacy cost by isolating and clipping only the sensitive information in the model logits (relative to the public logits). Second, we improve text quality by sampling without any privacy cost from a small superset of the top- k private tokens. Empirical evaluations demonstrate a consistent $8\times$ (or more) reduction in computation cost over state-of-the-art baselines to generate long-form private text of the same utility across privacy levels. **INVISIBLEINK** is able to generate, for the first time, high-quality private long-form text at less than $4\text{--}8\times$ times the computation cost of non-private generation, paving the way for its practical use. We open-source a pip-installable Python package (`invisibleink`) for InvisibleInk at <https://github.com/cerai-iitm/invisibleink>.

1 Introduction

Large Language Models (LLMs) have demonstrated remarkable inference-time capabilities, synthesizing information from multiple sources into coherent responses via retrieval-augmented generation (RAG), and generating increasingly long and sophisticated outputs via the recent “deep research” and inference-time scaling paradigms [1–3]. Larger token budgets also allow these models to effectively “think,” enabling self-reflection and correction of potential errors during generation [4–8]. The power of these models, however, often relies on their ability to process and reason over vast amounts of information, including potentially sensitive data provided at inference time. This context might come from user prompts containing private details or documents retrieved by RAG systems from confidential knowledge bases. There is some risk that the model’s outputs, particularly in detailed long-form generation [9], could inadvertently leak sensitive details from this private context [10]. Differential Privacy (DP) [11] can mitigate such risks by providing provable guarantees that the output distribution is statistically indistinguishable whether or not any single piece of sensitive information was included in the input context. This guarantee is not just desirable but often essential in sensitive domains like healthcare and finance, where information leakage carries severe regulatory (e.g., HIPAA, GDPR) and ethical consequences and merely anonymizing personally identifiable information (PII) is not sufficient [12]. Therefore, developing effective DP mechanisms for inference-time generation is critical for the responsible application of LLMs in privacy-sensitive applications. We tackle the challenge of achieving high-fidelity, long-form text generation under the rigorous DP guarantees on sensitive source text(s) used as references for generation.





با تشکر از توجه شما

