




دانشگاه اصفهان

دانشکده مهندسی کامپیوتر - گروه هوش مصنوعی و رباتیک

گزارش گام دوم از پروژه‌ی درس پردازش زبان‌های طبیعی

InvisibleInk: High-Utility and Low-Cost Text Generation with Differential Privacy



پدیدآورنده:

محمد امین کیانی

۴۰۴۳۶۴۴۰۰۸

دانشجوی کارشناسی ارشد، دانشکده‌ی کامپیوتر، دانشگاه اصفهان، اصفهان،
Aminkianiworkeng@gmail.com

استاد درس: دکتر برادران

نیمسال دوم تحصیلی ۱۴۰۴-۰۵

گام دوم : گزارش تحلیلی مقاله

بیان مسئله

مدل‌های زبانی بزرگ (LLMs) در تولید متن مبتنی بر اطلاعات بازیابی‌شده (مانند RAG) بسیار قدرتمند هستند اما زمانی که این اطلاعات شامل داده‌های حساس و خصوصی باشند (مثل پرونده‌های پزشکی یا حقوقی)، خطر نشت اطلاعات خصوصی در متن تولیدشده وجود دارد. روش‌های پیشین که از حریم خصوصی تفاضلی (DP) برای تولید متن استفاده می‌کردند، دارای محدودیت‌های عملی شدیدی بودند؛ از جمله اینکه به سربار محاسباتی بسیار بالایی (بیش از ۱۰۰ برابر تولید متن معمولی) نیاز داشتند تا متنی معنادار تولید کنند. همچنین، به دلیل استفاده از نمونه‌برداری با دمای بالا (High-temperature sampling) از کل دایره لغات، کیفیت متن تولیدی آن‌ها به شدت افت می‌کرد و متنی نامفهوم تولید می‌شد. مقاله حاضر سعی دارد با کاهش هزینه محاسباتی و حفظ کیفیت متن، این مشکل را حل کند.

ساختار معماری و نوآوری‌های مقاله

این مقاله از معماری استاندارد مدل‌های زبانی خودهمبسته (Autoregressive LLMs) مبتنی بر ترانسفورمر (مانند TinyLLaMA و LLaMA3) به عنوان ساختار پایه استفاده می‌کند. با این حال، به جای تغییر در معماری آموزش، در مرحله استنتاج (Inference) و استراتژی رمزگشایی (Decoding) تغییر ایجاد می‌کند. نوآوری‌های اصلی مقاله، دو مورد زیر هستند:

- **تکنیک DClip (Targeted Clipping Function):** به جای برش مستقیم لاجیت‌های خصوصی، این الگوریتم ابتدا لاجیت‌های عمومی (بدون داده‌های حساس) را محاسبه کرده و تنها «تفاضل» بین لاجیت‌های خصوصی و عمومی را برش می‌دهد. فرمول آن به صورت زیر است:

$$DClip_C(\phi_i, \phi_{pub}) := \phi_{pub} + clip_C(\phi_i - \phi_{pub})$$

- **تکنیک نمونه‌برداری Top-k+ (Truncated Top-k+ Sampling):** به جای نمونه‌برداری از کل دایره لغات، یک مجموعه والد (Superset) کوچک از توکن‌های برتر با نام V_k^+ ایجاد می‌کند که بر اساس لاجیت‌های عمومی ساخته شده است و تضمین می‌کند که توکن‌های برتر خصوصی را نیز در بر می‌گیرد، بدون آنکه هزینه حریم خصوصی اضافه‌ای تحمیل کند.

نحوه اثرگذاری مکانیزم‌های جدید (درک مکانیزم)

- **دلیل اثربخشی DClip:** لاجیت‌های مدل زبانی به خودی خود حاوی اطلاعات عمومی زبان (گرامر، سینتکس و دانش عمومی) هستند. وقتی کل لاجیت‌ها برش داده می‌شوند، بودجه‌ی حریم خصوصی هدر می‌رود. مقاله با استفاده از DClip، این دانش عمومی را حفظ کرده و تنها روی اطلاعات جدیدی که از داده‌های خصوصی نشأت می‌گیرند، محدودیت و نویز اعمال می‌کند؛ این کار حساسیت را به شدت کاهش داده و اجازه می‌دهد از هزینه محاسباتی کمتری استفاده شود.

- **دلیل اثربخشی Top-k+ :** نمونه‌برداری از کل دایره لغات در روش‌های DP قبلی باعث می‌شد توکن‌های نامربوط شانس انتخاب پیدا کنند. با ایجاد آستانه $2C/B - 1$ روی لاجیت‌های عمومی، این مکانیزم دایره لغات را به توکن‌های منطقی محدود می‌کند و کیفیت متن را به شدت بالا می‌برد.

بررسی نتایج و ارزیابی (جدول اصلی نتایج)

۱. آیا مسئله به خوبی حل شده است؟ بله، چارچوب InvisibleInk موفق شده است برای اولین بار متن‌های طولانی (صدها توکن) با کیفیت بالا و با رعایت دقیق حریم خصوصی تولید کند.
۲. آیا کامپوننت‌ها اثر مطلوب داشته‌اند؟ بله، استفاده از این دو نوآوری منجر به کاهش ۸ الی ۱۶ برابری در هزینه‌های محاسباتی (نسبت به روش‌های پایه مانند Amin et al.) شده است، در حالی که کیفیت متن (ارزیابی شده با معیار MAUVE و MedNER) در همان سطح یا بهتر حفظ شده است.
۳. بهبود نتایج و انصاف در مقایسه (سخت‌افزار و محاسبات): بله، مقایسه کاملاً منصفانه است زیرا معیار اصلی مقاله، محدودیت بودجه محاسباتی (اندازه‌ی بیج B) است. مقاله از نظر تعداد پارامتر از مدل‌های ۱۰.۱ میلیارد پارامتری TinyLLaMA تا ۸ میلیارد پارامتری LLaMA3-8B را بررسی کرده است. در خصوص سخت‌افزار، آزمایش‌ها روی ۴ پردازنده گرافیکی NVIDIA RTX L40S 48GB و همچنین NVIDIA H100 80GB اجرا شده و زمان‌های اجرا (مثلاً ۴ ساعت برای تولید ۱۰۰۰ نمونه با ۱۵ بیج) به دقت گزارش شده‌اند.

ایرادات و کاستی‌های مقاله (نقد و بررسی)

بر اساس مطالعه تحلیلی این معماری، چند محدودیت و ایراد مشهود است:

- **نیاز به دسترسی جعبه‌سفید :** این روش نیازمند دسترسی مستقیم به لاجیت‌های مدل (Logits) در هر مرحله از تولید توکن است. این یعنی نمی‌توان از آن برای مدل‌های تجاری که فقط از طریق API در دسترس هستند (مانند GPT-4) استفاده کرد.
- **چالش تراز شدن مدل (Model Alignment) :** طبق گزارش خود مقاله، زمانی که این روش روی مدل‌های بزرگتر (مثل LLaMA3-8B) پیاده شد، کیفیت معیار MAUVE کمی افت کرد. دلیل آن مقاومت امنیتی مدل (Alignment) در تولید داده‌های حساس پزشکی بود که منجر به تولید متن‌های هشداردهنده (مثل "این یک خلاصه پرونده جعلی است") می‌شد.
- **سربار محاسباتی همچنان قابل توجه است :** اگرچه هزینه محاسباتی ۸ برابر کاهش یافته، اما همچنان برای تولید یک توکن، مدل باید $B+1$ بار اجرا شود (مثلاً ۸ یا ۱۶ بار). این موضوع سرعت استنتاج را در سیستم‌های Local به شدت کند می‌کند.