




تمرین صفرم پیش‌پردازش زبان طبیعی

تاریخ بارگذاری تمرین: ۱۴۰۵/۰۱/۲۹

تاریخ تحویل تمرین: ۱۴۰۵/۰۲/۱۰



۱ نصب پکیج‌ها

با توجه به عدم امکان دسترسی به مخازن اصلی در زمان نگارش تمرین، در صورتی که پکیج‌ها را از قبل روی سیستم خود ندارید، برای دریافت آن‌ها می‌توانید از میزورها استفاده نمایید. سعی کنید تا جای امکان میزورها را به صورت گلوبال روی سیستم خود تنظیم نکنید، و پیش از نصب پکیج‌ها یک venv بسازید. برای ساخت venv در زبان برنامه‌نویسی پایتون می‌توانید در پوشه‌ای که می‌خواهید پروژه خود را بسازید، دستور زیر را وارد نمایید.

venv

```
> python -m venv ./venv
```

سپس آن را براساس سیستم‌عامل خود فعال نمایید:

activating venv

```
# Linux, Mac
> source ./venv/bin/activate
# Windows
> venv\Scripts\activate
```

در نهایت پس از فعال‌سازی venv می‌توانید به نصب پکیج‌های خود بپردازید. برای مشخص کردن میزور می‌توانید از فلگ ^۱ -i استفاده نمایید:

Installing packages

```
> pip install -i [mirror_url] [package_name]
```

۲ پرسش‌ها

فرآیند ریشه‌یابی^۲ با لم‌سازی^۳ چه تفاوت‌هایی دارد؟ مثال بزنید.

^۱ Flag

^۲ Stemming

^۳ Lemmatization

۳ برنامه‌نویسی

دسته‌بندی^۴ یکی از عملیات‌های مرسوم یادگیری ماشین^۵ به حساب می‌آید. یکی از جنبه‌های این عملیات در زمینه‌ی پردازش زبان طبیعی^۶، دسته‌بندی متون است. در فایل‌های مربوط به تمرین، کد^۷ و مجموعه‌دادگان^۸ یک برنامه‌ی دسته‌بندی ساده آمده است که براساس الگوریتم دسته‌بندی k نزدیک‌ترین همسایگی^۹ عمل می‌کند. دادگان موجود مجموعه‌ای از نظرات^{۱۰} پلتفرم یوتیوب^{۱۱} را تشکیل می‌دهند. هدف این دسته‌بند، تشخیص اسپم^{۱۲} بودن یا نبودن این هر یک از این نظرات است. بدون اعمال پیش‌پردازش روی دادگان، این دسته‌بند به صحت^{۱۳} ۷۸ درصد می‌رسد. مجموعه‌ای از عملیات‌های پیش‌پردازش را به گونه‌ای انتخاب کنید که با اعمال آن‌ها روی دادگان، صحت مدل یاد شده افزایش یابد. در این راستا موارد زیر را در نظر بگیرید:

- فرض کنید مجموعه عملیات‌های پیش‌پردازش طراحی توسط شما شامل n گام باشد.
- گام نهایی (n ام) در عملیات پیش‌پردازش طراحی شده، می‌بایست یک بار الگوریتم ریشه‌یابی، سپس لم‌سازی و در نهایت تصحیح غلط^{۱۴} باشد.
- تمامی $n - 1$ عملیات قبلی در هر سه حالت یکسان در نظر گرفته شوند.
- به این ترتیب عملیات دسته‌بندی بایستی به‌ازای هر کدام از الگوریتم‌های یاد شده، یک‌بار و با مجموعه عملیات‌های پیش‌پردازش یکسان اجرا گردد.
- عملیات‌های پیش‌پردازش بایستی باتوجه به هدف مسئله‌ی دسته‌بندی و کثیفی‌های مجموعه‌دادگان طراحی گردند.
- حداقل تعداد پیش‌پردازش ممکن بایستی استفاده گردد (سعی کنید کم‌ترین مقدار برای $n - 1$ را بیابید).
- حداقل بهبود نتیجه صحت قابل قبول به عنوان پاسخ، ۸ درصد خواهد بود.
- پس از انجام اجراهای خواسته شده مشخص کنید کدام یک از الگوریتم‌های ریشه‌یابی، لم‌سازی و تصحیح غلط بهتر عمل می‌کنند. چرا؟
- آیا می‌توان با جایگزین کردن الگوریتم دسته‌بندی به نتایج بهتری دست پیدا کرد، الگوریتم پیشنهادی خود را مشخص نمایید و نتایج جدید را گزارش کنید. (اختیاری).

۴ خوانش مقاله

مقاله‌ی «On the effectiveness of preprocessing methods when dealing with different levels of class imbalance» [۱] را مورد مطالعه قرار دهید و به پرسش‌های زیر پاسخ دهید:

⁴Classification

⁵Machine learning

⁶Natural language processing

⁷Code

⁸Dataset

⁹K nearest neighbours

¹⁰Comments

¹¹Youtube

¹²Spam

¹³Accuracy

¹⁴Spell correction

۱. هدف مقاله را در یک یا دو جمله توضیح دهید.
۲. روش‌های بیش‌نمونه‌برداری^{۱۵} و کم‌نمونه‌برداری^{۱۶} که در مقاله آمده است را توضیح دهید. از هر کدام یک مثال بیاورید و به صورت خلاصه بگویید چگونه عمل می‌کنند.
۳. چرا معیار^{۱۷} صحت در مورد مجموعه‌دادگان با عدم‌توازن^{۱۸}، معیار خوبی نیست؟
۴. چه معیارهایی برای بررسی نتایج الگوریتم‌ها روی مجموعه‌دادگان با عدم‌توازن معرفی شده است، آن‌ها را به طور خلاصه توضیح دهید؟ چرا بهتر هستند؟
۵. آیا مجموعه‌داده نظرات یوتیوب فراهم شده در بخش ۳ (برنامه‌نویسی) دارای عدم‌توازن است؟
۶. یکی از معیارهای معرفی شده در مقاله را بر روی مجموعه‌داده بخش ۳ (برنامه‌نویسی) امتحان و نتیجه را گزارش کنید.
۷. نتیجه‌ی مقاله چیست؟

۵ نکات تحویل

۱. پاسخ خود را تحت پوشه‌ای به اسم NLP_YOUR-NAME_ID و در قالب zip بارگذاری نمایید.
۲. این پوشه می‌بایست حاوی موارد زیر باشد:
 - پوشه‌ای با نام code باشد که شامل برنامه‌ی نوشته/تغییر داده شده است.
 - پوشه‌ای با نام doc که حاوی داکيومنت‌ها و فایل توضیحات می‌باشد.
۳. لازم به ذکر است که رعایت قوانین نگارشی حائز اهمیت خواهد بود.

مراجع

- [1] V. García, J. S. Sánchez, and R. A. Mollineda, "On the effectiveness of preprocessing methods when dealing with different levels of class imbalance," *Knowledge-Based Systems*, vol.25, no.1, pp.13–21, 2012.

¹⁵Over-sampling

¹⁶Under-sampling

¹⁷Metric

¹⁸Imbalance